

# Algoritmo de ramificación y acotamiento

Angélica M. González O.

Universidad EAFIT

# Método del gradiente

El gradiente es un vector en un punto  $\mathbf{x}$  que proporciona la dirección (local) de máxima variación de la función. En la búsqueda de un mínimo la dirección de movimiento será contragradiante:

$$\mathbf{s}^k = -\nabla f(\mathbf{x})$$

La transición de un punto  $\mathbf{x}^k$  a otro punto  $\mathbf{x}^{k+1}$  viene dada por la siguiente expresión:

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \Delta \mathbf{x}^k = \mathbf{x}^k + \lambda^k \mathbf{s}^k = \mathbf{x}^k - \lambda^k \nabla f(\mathbf{x}^k)$$

con:

$\Delta \mathbf{x}^k$  = Vector desde  $\mathbf{x}^k$  hasta  $\mathbf{x}^{k+1}$

$\mathbf{s}^k$  = Dirección de búsqueda de máximo descenso

$\lambda^k$  = Escalar que determina la longitud de paso en la dirección  $\mathbf{s}^k$

# Algoritmo práctico

- Elegir un valor inicial  $x^0$ . En pasos sucesivos se considera  $x^k$
- Calcular las derivadas parciales.

$$\frac{\partial f(x)}{\partial x_j} \quad j = 1, 2, 3, \dots, n$$


- Calcular el vector de búsqueda

$$s = -\nabla f(x^k)$$

- Usar la relación  $x^{k+1} = x^k + \lambda^k s^k$  para obtener el siguiente punto. El valor de  $\lambda^k$  puede ser de valor fijo o calculado en cada paso mediante una búsqueda unidireccional.
- Comparar  $f(x^{k+1})$  con  $f(x^k)$ . Si el cambio es menor que una tolerancia pre-especificada se debe terminar, en caso contrario volver al paso dos y continuar con las iteraciones.

# Ejemplo

**Ejemplo** Hallar el mínimo de  $Z = f(x, y) = x^2 - 24x + y^2 - 10y$   
con valor inicial  $x^0 = (8, 7)$



# Newton

La idea principal del método consiste en minimizar localmente una función  $f$  con una función cuadrática. Así, cerca del valor  $x_k$  podemos aproximar  $f$  mediante la [serie de Taylor](#) truncada

$$f(x) = f(x_0) + \left. \frac{df(x)}{dx} \right|_{x=x_0} (x - x_0) + \frac{1}{2!} \left. \frac{d^2f(x)}{dx^2} \right|_{x=x_0} (x - x_0)^2 + \dots$$

$$f(x) \approx f(x^k) + \nabla f^T(x^k)(x - x^k) + \frac{1}{2}(x - x^k)^T \nabla^2 f(x^k)(x - x^k)$$

# Newton

La idea principal del método consiste en minimizar localmente una función  $f$  con una función cuadrática. Así, cerca del valor  $x_k$  podemos aproximar  $f$  mediante la [serie de Taylor](#) truncada

$$f(x) = f(x_0) + \left. \frac{df(x)}{dx} \right|_{x=x_0} (x - x_0) + \frac{1}{2!} \left. \frac{d^2f(x)}{dx^2} \right|_{x=x_0} (x - x_0)^2 + \dots$$

$$f(x) \approx f(x^k) + \nabla f^T(x^k)(x - x^k) + \frac{1}{2}(x - x^k)^T \nabla^2 f(x^k)(x - x^k)$$

Sea  $x^{k+1}$  un mínimo único dado por:

$$\nabla f(x^k) = -\nabla^2 f(x^k)(x^{k+1} - x^k)$$

# Newton

La idea principal del método consiste en minimizar localmente una función  $f$  con una función cuadrática. Así, cerca del valor  $x_k$  podemos aproximar  $f$  mediante la [serie de Taylor](#) truncada

$$f(x) = f(x_0) + \left. \frac{df(x)}{dx} \right|_{x=x_0} (x - x_0) + \frac{1}{2!} \left. \frac{d^2f(x)}{dx^2} \right|_{x=x_0} (x - x_0)^2 + \dots$$

$$f(x) \approx f(x^k) + \nabla f^T(x^k)(x - x^k) + \frac{1}{2}(x - x^k)^T \nabla^2 f(x^k)(x - x^k)$$

Sea  $x^{k+1}$  un mínimo único dado por:

$$\nabla f(x^k) = -\nabla^2 f(x^k)(x^{k+1} - x^k)$$

La solución para la recurrencia  $x^{k+1}$  esta dada por

$$x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$



# Ejercicio

**Ejercicio** Dada la función  $f(x) = 10x_1^2 + x_2^2$  y un punto inicial  $x^0 = (1, 2)^T$ . Calcular el mínimo utilizando el algoritmo de Newton.

# Ejercicio

**Ejercicio** Dada la función  $f(x) = 10x_1^2 + x_2^2$  y un punto inicial  $x^0 = (1, 2)^T$ . Calcular el mínimo utilizando el algoritmo de Newton.

**Ejercicio** Si el método de Newton se inicia cerca al mínimo local  $\vec{x}$ , con la Hessiana  $H(\vec{x})$  definida positiva, entonces converge cuadráticamente a la solución.

## Theorem

Sea  $f : \mathbb{R} \rightarrow \mathbb{R}$  continua doblemente diferenciable. Considere el algoritmo de Newton definido por  $A(x) = x - H(x)^{-1} \nabla f(x)$ . Sea  $\bar{x}$  tal que  $\nabla f(\bar{x}) = 0$  y  $H(\bar{x})^{-1}$  existe. Iniciando con el punto  $x_1$  suficientemente próximo a  $\bar{x}$  esta proximidad implica que existen un  $k_1, k_2 > 0$  con  $k_1 k_2 \|x_1 - \bar{x}\| < 1$  tal que

①  $\|H(\bar{x})^{-1}\| \leq k_1$

y por expansión en la serie de Taylor de  $\nabla f$ ,

②  $\|\nabla f(\bar{x}) - \nabla f(x) - H(x)(\bar{x} - x)\| \leq k_2 \|\bar{x} - x\|^2$

Para cada  $x$  que satisface  $\|x - \bar{x}\| \leq \|x_1 - \bar{x}\|$ . Entonces el algoritmo converge superlinealmente a  $x$  con al menos una tasa de convergencia de orden dos o cuadrática.